

# 応用数学・要点まとめ

## 第1章 線形代数

### □ 逆行列

元の行列  $A$  との積が単位行列  $I$  になる行列  $A^{-1}$ :  $AA^{-1} = A^{-1}A = I$

逆行列  $A^{-1}$  は、掃き出し法(左右の係数の行列に同じ基本変形を実行)によって求める:

$$\begin{aligned} \left( \begin{array}{cc|cc} 1 & 4 & 1 & 0 \\ 2 & 6 & 0 & 1 \end{array} \right) &\xrightarrow{\substack{2 \text{ 行目を} \\ 1/2 \text{ 倍}}} \left( \begin{array}{cc|cc} 1 & 4 & 1 & 0 \\ 1 & 3 & 0 & 1/2 \end{array} \right) \xrightarrow{\substack{1 \text{ 行目に } 2 \text{ 行目の} \\ -1 \text{ 倍を加える}}} \left( \begin{array}{cc|cc} 0 & 1 & 1 & -1/2 \\ 1 & 3 & 0 & 1/2 \end{array} \right) \\ &\xrightarrow{\substack{2 \text{ 行目に } 1 \text{ 行目} \\ \text{の } -3 \text{ 倍を加える}}} \left( \begin{array}{cc|cc} 0 & 1 & 1 & -1/2 \\ 1 & 0 & -3 & 2 \end{array} \right) \xrightarrow{\substack{1 \text{ 行目と } 2 \text{ 行目} \\ \text{を入れ替える}}} \left( \begin{array}{cc|cc} 1 & 0 & -3 & 2 \\ 0 & 1 & 1 & -1/2 \end{array} \right) \end{aligned}$$

逆行列

### □ 行列式

$$\begin{vmatrix} a & b \\ c & d \end{vmatrix} = ad - bc$$

$$\begin{vmatrix} a & b & c \\ d & e & f \\ g & h & i \end{vmatrix} = a \begin{vmatrix} e & f \\ h & i \end{vmatrix} - b \begin{vmatrix} d & f \\ g & i \end{vmatrix} + c \begin{vmatrix} d & e \\ g & h \end{vmatrix}$$

行列式の特徴:

同じ行ベクトルが含まれると行列式は 0

1 つのベクトルが  $\lambda$  倍されると行列式は  $\lambda$  倍される

他の成分が全部同じで  $i$  番目のベクトルだけが違った場合、行列式の足し合わせになる

行を入れ替えると符号が変わる

← 入れ替えた前後の行列を加えると操作した 2 つの行が同じになり、行列式が 0 になるため

### □ 固有値分解

$A\vec{x} = \lambda\vec{x}$      $\lambda$ : 固有値、 $\vec{x}$ : 固有ベクトル  $\Rightarrow$  主成分分析による次元削減で利用

$|A - \lambda I| = 0$     固有値が存在する条件

$A = \begin{pmatrix} 1 & 4 \\ 2 & 3 \end{pmatrix}$  の場合、 $\begin{vmatrix} 1-\lambda & 4 \\ 2 & 3-\lambda \end{vmatrix} = 0$  より、 $(1-\lambda)(3-\lambda) - 8 = 0 \rightarrow \lambda = 5 \text{ or } -1$

$\lambda = 5$  の時、 $\begin{pmatrix} 1 & 4 \\ 2 & 3 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = 5 \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$  より、 $x_1 = x_2 \rightarrow \vec{x} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$  の定数倍

$\lambda = -1$  の時、 $\begin{pmatrix} 1 & 4 \\ 2 & 3 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = -1 \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$  より、 $x_1 = -2x_2 \rightarrow \vec{x} = \begin{pmatrix} 2 \\ -1 \end{pmatrix}$  の定数倍

$$\Leftrightarrow AV = V\Lambda \rightarrow A = V\Lambda V^{-1} \quad \text{ここで、} A: \text{正方行列、} \Lambda = \begin{pmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \ddots \end{pmatrix}, V = \begin{pmatrix} \vec{v}_1 & \vec{v}_2 & \dots \end{pmatrix}$$

### □ 特異値分解

正方行列以外は固有値分解できないため、その拡張として特異値分解を用いる  $\Rightarrow$  次元削減で利用

$M\vec{v} = \sigma\vec{u}$ 、 $M\vec{u} = \sigma\vec{v}$  となる特殊な単位ベクトルがある  $\Rightarrow M = USV^{-1}$  特異値分解

$MV = US \rightarrow M = USV^{-1}$ 、 $M^T U = V S^T \rightarrow M^T = V S^T U^{-1}$

これらの積  $MM^T = US S^T U^{-1}$ 、 $M^T M = V S^T S V^{-1}$

# 応用数学・要点まとめ

$MM^T(M^TM)$ を固有値分解すれば、その左特異ベクトル  $U$ 、右特異ベクトル  $V$ (単位ベクトル)と特異値の2乗が求められる

## 第2章 確率・統計

### ▣ 確率

- 確率の種類:

頻度確率(客観確率): 発生する頻度

ベイズ確率(主観確率): 信念の度合い

- 条件付き確率: ある事象  $X=x$  が与えられた下で、 $Y=y$  となる確率

$$P(Y=y | X=x) = P(Y=y, X=x) / P(X=x)$$

- 独立な事象の同時確率

$$P(X=x, Y=y) = P(X=x)P(Y=y) = P(Y=y, X=x)$$

- ベイズ則: 一般的に事象  $X=x$  と事象  $Y=y$  に対して以下が成立

$$P(X=x | Y=y)P(Y=y) = P(Y=y | X=x)P(X=x)$$

### ▣ 確率変数と確率分布

- 確率変数: 事象と結び付けられた数値(事象そのものを指すと解釈する場合も多い)
- 確率分布: 事象の発生する確率の分布(拡散値であれば表に示せる)

### ▣ 期待値と分散・共分散

- 期待値:  $E(f) = \sum_{k=1}^n P(X=x_k) f(X=x_k)$  ... 離散値の場合

$$E(f) = \int P(X=x) f(X=x) dx \quad \dots \text{連続値の場合}$$

- 分散: データの散らばり具合(期待値からのズレの平均):

$$\text{Var}(f) = E[(f(X=x) - E(f))^2] = E(f^2(X=x)) - (E(f))^2$$

- 共分散: 2つのデータ系列の傾向の違い(正は似た傾向、負は逆の方向、0は関係性に乏しい):

$$\text{Cov}(f, g) = E[(f(X=x) - E(f))(g(Y=y) - E(g))] = E(fg) - E(f)E(g)$$

### ▣ 様々な確率分布

- ベルヌーイ分布: コイントスのイメージ(裏と表で出る割合が等しくなくても扱える)

$$P(X | \mu) = \mu^x (1 - \mu)^{1-x}$$

- マルチヌーイ(カテゴリーカル)分布: さいころを転がすイメージ(各面の出る割合が等しくなくても扱える)
- 二項分布: ベルヌーイ分布の多試行版

$$P(X | \lambda, n) = \binom{n}{x} \lambda^x (1 - \lambda)^{n-x}$$

- ガウス分布: 釣鐘型の連続分布

$$N(x; \mu, \sigma^2) = \sqrt{\frac{1}{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right)$$

## 第3章 情報理論

### ▣ 自己情報量

## 応用数学・要点まとめ

**情報量**： ある事象が起きた際、それがどれほど起こりにくいかを表す尺度。

その事象が本質的にどの程度の情報を持つかの尺度とみなせる(有用性とは無関係)。

**自己情報量**： それぞれの事象の情報量

ある事象  $X$  が起こる確率  $P(x)$ 、情報の変化率を  $W(x)$  とすると、

$$I(x) = -\log_s(P(x)) = \log_s(W(x))$$

$S=2$  の時はビット(bit)、 $S=e$  (ネイピア) の時はナット(nat)

**シャノンエントロピー**： 自己情報量の期待値

$$H(x) = E(I(x)) = -E(\log(P(x))) = -\sum P(x) \log(P(x))$$

▣ カルバック・ライブラー・ダイバージェンス (Kullback-Leibler divergence, KL 情報量)

• カルバック・ライブラー・ダイバージェンス： 2つの確率分布がどの程度似ているかを表す尺度

$$D_{KL}(P\|Q) = E_{X \sim P} \left[ \log \frac{P(x)}{Q(x)} \right] = E_{X \sim P} [\log P(x) - \log Q(x)] = \sum_x P(x) \log \frac{P(x)}{Q(x)}$$

• 交差エントロピー： KL ダイバージェンスの一部分を取り出したもの、 $Q$  についての自己情報量を  $P$  の分布で平均

$$H(P, Q) = H(P) + D_{KL}(P\|Q) = -E_{X \sim P} [\log Q(x)] = -\sum P(x) \log(Q(x))$$



3ヶ月で現場で潰しが効く  
**ディープラーニング講座**

 Study-AI

詳しくはこちら ▶